

自主化学机理压缩：理论框架、实验结果与失败模式

截至 2026 年 9 月 16 日的研究滚动报告

版本：v1.0 | 用途：飞书研究文档 / 团队讨论 / 论文证据整理 | 状态：内部实证工作稿，不是已审定论文结论。

数据快照：2026-09-16T13:15:10.014106+00:00。本轮只核对、汇总已经产生的结果，没有新启动科学计算或付费模型评审。

阅读建议：先看第 1、5、6 节了解结论；第 7–10 节用于专家复盘；第 12–14 节界定论文能说什么、还缺什么。全部候选、逐工况误差和来源索引随文提供。

1. 一页结论：现在究竟做成了什么

已经做成：Agent 可以从 USC-II 父机理出发，自行组织简化方法与验证，并输出在独立统一评测中保持完整覆盖的压缩机理。但“能压缩”与“能可靠地定义适用域、验证自己、持续进化”是不同层次的能力。后几项仍是当前短板。

当前主实验包含 GPT + Codex、Kimi + Kimi Code、DeepSeek + Codex 三种模型与 Harness 组合，每种又分普通 / 专家任务提示、Solo / Team，共 12 个实验单元。它们是探索性单次轨迹，不是 12 次同条件重复。

本次核对了 10 组的终点评分，共 30 个非父机理候选、18,300 条候选×工况记录。每个候选均对同一 610 工况登记结果；其中 10 个候选成功求解全部 610 工况。另两组 DeepSeek 轨迹尚无确认终点，不能填零分，也不能假定已经完成。

值得优先讨论的四个结果：

- 目前完整覆盖候选中，最低全池平均误差来自 DeepSeek 专家 Solo：89 物种 / 671 反应， $E = 2.6146$ 。**相比父机理 111 / 784、 $E = 2.6677$ ，物种减少 19.82%，反应减少 14.41%， E 下降约 1.99%。这是数值结果，不是统计显著性结论，也不是整体性价比冠军。
- GPT 普通 Solo 的 87 / 513 是另一种很有竞争力的折中： $E = 2.6232$ ，物种减少 21.62%，反应减少 34.57%。**它比上述 DeepSeek 候选更小，但全池 E 略高。不存在不定义偏好就唯一成立的“最优机理”。
- 完整覆盖候选中，物种最少的是 Kimi 专家 Team 的 70 / 507： $E = 2.8948$ 。**物种减少 36.94%，代价是 E 相对父机理增加约 8.51%。这里的 8.51% 是标准化平均误差这个指标的相对变化，不是“所有预测偏差 8.51%”。
- 20 / 30 个候选未实现完整覆盖。**很多失败来自输入燃料物种被删，也有数值求解失败、点火观测量未解析。它们可能适合自己声明的窄域，但不能据此声称适合这套完整跨工况评测域。

当前最稳妥的研究解释不是“哪家模型一定更强”，而是：**自主科研 Agent 已完成方法实现和局部验证，但其适用域定义、证据覆盖和最终停止判断经常没有与宏观任务目标一致。更多检索、更多算例、更多子 Agent，本身都不能保证这一点。**

2. 科学问题：为什么不是普通代码生成

2.1 任务对象与下游价值

一个化学动力学机理不只是一张反应清单，还包括物种、反应结构、速率表达式、热力学和输运数据。机理参与反应器 ODE 或反应流 PDE 求解；任何局部删减，都可能在不同燃料、温度、压力、当量比或观测量上产生不同后果。

本项目的实际任务是：**在物理化学与数值约束下，寻找跨工况有效的宏观误差—复杂度折中，重点实现有依据的机理压缩**。不要求每个中间物种的瞬态都逐一复现父机理，也不要求每个工况都比父机理更准。

下游目标是降低反应流模拟中的化学计算负担，为燃烧装置设计、参数扫描、控制和不确定性分析提供可用的简化机理。物种 / 反应数减少只是复杂度代理；实际加速还受刚性、Jacobian 结构、输运和网格等影响。本轮没有测得统一的 CFD 加速比，不能由物种压缩率直接推算加速倍数。

本轮不是分子级新反应发现，也尚未覆盖真实多物理场的全部复杂性。准确说，它是面向宏观 ODE / PDE 的**自主机理压缩与适用域验证**。长期才扩展到机理修订、跨任务策略进化、二维 / 三维反应流以及 SootGEN 和专家验证。

2.2 形式化目标

令机理为 M ，复杂度由物种数 $N_s(M)$ 、反应数 $N_r(M)$ 分别描述；工况为 x ，实验宏观观测为 y ，求解器输出为 $f(M, x)$ 。

- 科学目标：减小宏观误差 $E(M)$ ，同时减小 $N_s(M)$ 、 $N_r(M)$ 。
- 约束：元素守恒、机理可加载、反应与物种引用完整、适用的热力学 / 速率约束、输入兼容，以及数值求解与观测提取要求。
- 证据要求：一个候选在自己挑选的工况上表现好，不等于在统一评测域上表现好。

可以把搜索结果画成横轴压缩率、纵轴误差的图，寻找右下方的非支配点。但“覆盖不足”的候选必须额外标出，不能靠跳过困难工况得到更低的平均误差。

2.3 Agent 究竟负责哪一环

环节	Agent 的科学决策	环境 / 工具的责任
定义适用域	要覆盖哪些燃料、温压范围与观测量	保存任务契约，检查声明与数据来源
获取证据	搜索什么、信任哪些来源、缺什么证据	记录查询、返回内容、提取值和来源
设计方法	选 DRGEP、敏感性分析、恢复、拟合或自写方法	执行代码，提供真实求解与错误诊断
设计验证	哪些算例值得算、怎样分组和留作确认	统一单位、返回逐工况原始值、记录成本
迭代与停止	根据失败修改什么，何时足以提交	锁定候选、独立评测，不擅自改变评分

因此，LLM 的研究价值不只是调用一次 DRGEP，而是把“领域—数据—方法—验证—停止”组织成可靠的决策过程。成熟 Harness 提供执行与上下文能力；它不会自动替代科学任务的适用域判断。

3. 长期理论：RSI、状态、记忆和技能分别是什么

3.1 三种变化不能混为一谈

变化	例子	当前应如何称呼
优化对象变化	从 111 物种删到 87 物种	机理搜索取得了进展
当前任务策略变化	发现乙炔退化后增加火焰验证、恢复相关通路	反馈驱动的任务内适应
可复用的优化能力变化	把失败转为有适用条件的验证程序，在后续独立阶段减少同类失败	程序经验 / 技能进化的候选证据

机理变小，不自动等于 Agent 自我进化；写了一份 skill，也不自动等于以后真的会更会做科研。 要主张 RSI，至少要证明修订的策略被后续决策实际读取和使用，并在排除继承更优候选、额外计算或测试泄漏后带来收益。

长期方案中，“可进化对象”不应只限于自然语言 memory，也可以是算例选择器、验证 workflow、检索策略、工具包装或技能程序。但评分器、物理不变量、凭据和权威成本账本不能由被评测 Agent 任意修改。

3.2 面向长程科研的知识状态

建议把状态拆成以下对象；这是研究架构的定义，不宣称每项均已实现并通过本轮消融。

对象	应保存什么	为什么不能只靠对话历史
运行状态	作业、会话、预算、等待与故障状态	进程活着不代表科学动作在推进
原始证据库	case 输入、求解值、误差、状态、日志、来源	必须完整保存且可以重新计算汇总
当前科研状态	候选前沿、覆盖矩阵、主要损伤、未决假设	模型不应每轮重读成千上万条原始结果
程序记忆	条件→动作、依据、反例、启用版本	防止把偶然补偿规律写成永久规则
技能	可执行的检索、构造、验证或分析程序	代码可复用，但仍需测试其正确性和适用域

对应流程应是：原始证据追加保存 → 程序精确聚合统计 → 按当前问题检索相关证据 → Agent 决策 → 执行并检验 → 提出策略修订 → 在后续预先界定的场景验证、启用或撤销。

例如，不必让模型为了定位异丁烯退化重读全部文件。程序可以给它“该候选在异丁烯 IDT 组有 28 个评测点、误差怎样变化、哪些失败”，再允许追溯每个点的原始求解与来源。聚合值由程序计算，研究假设由模型提出，两者分开。

3.3 本轮对 RSI 能提供什么证据

本轮保留了候选与原始记录，并观察到 Agent 自写工具、修复代码、增加验证、改变适用域等行为。但当前 Solo / Team × 提示词 × 模型实验，不是一套已经完成的“固定程序记忆 vs 演化程序记忆”配对实验。

早期 A / B / C 三控制器方案、从相同 M0 开始的多阶段记忆升级方案，属于不同版本的研究设计。不能把后来的成熟 Harness 跑通和本轮候选成绩，倒填为早期 C 比 B 更优的证据。当前可说“发现了值得研究的进化对象与失败模式”，尚不能说“已证明 RSI 的因果收益”。

3.4 动态代理、贝叶斯选点和程序记忆如何配合

此前讨论的算法思路，可以统一解释为“在有限预算下，减少对下一步决策没有帮助的计算和历史读取”。它与当前实验成绩要分开：本轮没有完成相应模块的独立消融，因此不声称下面每项都已带来收益。

第一层是动态代理模型：用已经实算的候选×工况结果估计尚未计算区域的宏观误差，并给出不确定度。它不是用 DRGEP 关联排名直接代替误差，更不能把 LLM 的自信当作校准后的后验。对于输入缺失、求解失败和域外预测，应显式建模或拒绝可靠性承诺。

第二层是主动实验设计：选择最可能改变候选排序、暴露覆盖缺口或检验研究假设的下一批计算。一个概念性的决策准则是“预期减少的决策风险 / 预期计算成本”，而不是只算预计误差最小或最快的点。早期需要覆盖探索，后期可集中确认前沿附近的候选；这种分配策略也应通过实测比较。

第三层是检索与程序记忆：把原始记录按候选、工况家族、观测、失败类型和假设索引；程序计算覆盖和损伤摘要，模型只检索当前判断所需的证据。若某种修复策略多次在预先声明的适用域奏效，再把它登记为可复用程序经验，并保留反例与撤销条件。

三者形成闭环：代理指出哪里不确定 → Agent 选择验证 / 修复动作 → 实算更新证据 → 后验与覆盖状态更新 → 对可复用策略作前瞻检验。当前允许 Agent 自己构建开发工况时，这个闭环应在其可获取的公开材料和自设计工况上运行，不得访问独立评分池来选点。

“稀疏、可识别、跨工况稳定”的记忆要求，是为了避免把局部补偿当作长期规律：少量明确动作、可定位的证据、预先写明的适用条件、后续反例检查，比“这样改通常会更好”的泛化总结更可检验。即便如此，观察性一致仍不足以单独证明反应层面的因果机制。

4. 实验设置：同什么、不同什么

4.1 模型、Harness 与组织形式

组合	主 Agent 配置（运行记录）	Team 子 Agent 配置	比较边界
GPT + Codex	GPT-6 Astra / xhigh	GPT-5.5 / high，最多两个子 Agent	Team 是混合模型，不能纯归因于协作
Kimi + Kimi Code	kimi-k3 / max	同系列配置，最多三个 Agent 含主 Agent	与 GPT 的比较同时改变模型与 Harness
DeepSeek + Codex	deepseek-flash / max	同模型配置，最多三个 Agent 含主 Agent	max 是请求配置，不等于已观测到内部推理过程

Solo 不创建子 Agent。上表来自既有运行配置记录；本轮受本地文件系统故障影响，没有重新读取所有配置快照。终点评测文件能确认运行归属、候选、工况和评分，但本身不是模型服务请求的身份审计记录。

各单元只有一条主轨迹。模型随机性、提示词变化、修复版本、网络和算力调度都可能影响结果。不能据此形成通用模型榜单，或声称 Team 有统计显著优势。

4.2 普通提示和专家提示有什么差别

普通任务要求从 USC-II 出发，寻找跨工况、宏观精度可信的简化机理；不把 610 评测工况直接交给 Agent，也不预先指定一定使用 Cantera 或 DRGEP。Agent 自行查找公开材料、建立自己的测试集与方法，提交最多三个最终候选。

专家提示在普通任务上增加了一整套科研指导：参考 FFCM / SFCPD、ReSpecTh、ChemKED 等资源；追溯原始实验方法；显式定义应用域与覆盖；处理观测定义、单位和不确定度；区分方法开发和确认验证；对工具实现做对照检查；说明哪些知识改变了决策。

因此这不是“只加几个网站链接”的消融，也不是纯改写句式。它是**领域资源 + 方法学要求**的联合干预。后续若要知道到底哪项有效，需要再拆开实验。

原任务也给了 Agent 选择适用范围的空间，没有列出必须保护全部 610 工况输入燃料的硬清单。因此，缺失某类燃料可以说明对统一评测域覆盖不足，却不能不看其声明就一律定性为违背明确指令。

4.3 搜索与评测必须分开理解

搜索阶段：Agent 自己组织工况、文献、父机理对比和数值验证；不同轨迹看到的数据不同。它们自己的几百或上千次测试不等于评测池的 610 个实验工况，也不等于同数量的独立实验研究。

终点阶段：Agent 提交并锁定候选文件后，独立系统执行固定 610 工况。评分合同明确不把端点反馈回流到该轮搜索，不允许以此自动恢复优化。评测核时单独记账，不扣搜索预算。

固定池沿用历史的 491 开发 + 119 回查划分。该池在项目历史上已有暴露，**本报告称“固定统一终点评测”或“历史回查”，不称 pristine blind test**。当前 Agent 没拿到池子，不会自动洗掉项目层面的历史暴露。


当前运行方案记录的搜索上限为每组 512 分配核时 / 24 小时；独立端点评测另有上限。较新的 Kimi / DeepSeek 运行取消了模型美元和调用次数硬上限。GPT 走订阅的用量不是等额现金扣款。本轮没有重新核清完整搜索成本账本，不能作费用效率排名。

5. Benchmark 与评分：数字到底代表什么

5.1 当前固定池的构成

统一父机理为 USC-II：111 物种、784 反应。池中有 610 个唯一工况 ID，18 个燃料标签，320 个点火延迟

(IDT) 与 290 个层流火焰速度 (LFS) 工况。LFS 使用一维自由传播预混火焰求解，属于 PDE 证据；不是只有零维反应器。



固定池构成

此前数据审计记录的范围为：IDT 温度约 1054–2005 K、压力 0.3–262.5 atm；LFS 入口温度约 295–470 K、压力 0.5–25 atm。它仍缺少低温 / RCM、芳香族评测、组分割面、熄火、二维 / 三维和 soot 任务。不能把“18 类燃料标签”写成“覆盖全部燃烧化学”。

当前微平均中，每个工况点等权，但燃料不等权：乙烷有 97 点，异丁烷只有 4 点，权重相差 24.25 倍。全池均值必须配合燃料×观测分组结果阅读。

5.2 本轮真实使用的误差定义

本次从逐工况原始预测和观测字段重新计算了所有成功候选记录的 signed_sigma，并核对汇总值。实际定义为：

- IDT: $\text{signed_sigma} = \ln(\text{预测 IDT} / \text{实验 IDT}) / \sigma_{\log}$ 。
- LFS: $\text{signed_sigma} = (\text{预测 LFS} - \text{实验 LFS}) / \sigma_{\text{absolute}}$ 。
- 工况误差: $e_i = |\text{signed_sigma}_i|$ 。
- 完整全池误差: $E(M) = \sum e_i / 610$ ，仅在全部 610 工况成功时给出。
- 物种压缩率: $1 - N_s / 111$ ；反应压缩率: $1 - N_r / 784$ 。

这些 E 是按实验不确定度归一化后的无量纲误差，不是百分比。 σ 的解释来自数据适配规则；如果原始来源的不确定度定义有问题，E 也会受影响。本轮核对的是“按现有规则是否算对”，不是重新证明每篇文献的 σ 解释都正确。

父机理在本池成功 610 / 610， $E = 2.6677088561$ 。父机理也会偏离实验。简化机理局部更接近实验是可能的，但既可能来自有效保留 / 修正，也可能来自误差补偿；只看均值下降不能确认因果化学改进。

5.3 失败怎样计入

状态	本报告解释	不允许的处理
success	求解与观测提取成功；仍可能误差很大	把成功率当作精度合格率
input_incompatible	候选缺少输入混合物所需物种	扔掉这些点后声称全池通过
unresolved_observable	既定求解 / 时间窗口内未得到合格观测量	直接认定实验错误或物理上永不点火
numerical_failure	求解器 / 数值过程失败，需读取诊断	一律归因于机理质量或模型智力

只要不完整，全池 E 就记为 “—”，另存成功子集均值与覆盖率。本报告没有擅自给失败工况补 0，也没有根据本轮结果新设处罚常数。

此前提出“压缩与误差 6:4”的 grader 想法，不代表已有唯一冻结的标量奖励。本轮原始评分仍报告误差、复杂度和覆盖，没有为了得到一个总冠军而后加权重。

5.4 评测一致性与剩余风险

本次核对的 10 个有效端点，其工况内容的规范化校验值一致，科学适配器的 source pins 一致，记录的求解器均为 Cantera 3.0.1。所有 30 个候选均有 610 个唯一的结果记录；成功数、逐点误差和汇总均值已重新计算核对。

这证明了当前表格采用一致的计算对象和指标实现，但不等于实验观测算子绝对正确。已有审计还提出：不同火焰实验技术映射为统一 FreeFlame 观测的合理性、文献不确定度语义、跨页面实验批次归并等需要继续核实。源数据中的 campaign_group 仍有待完成文献组件映射。

不能因为父机理在某些点有 14–17 σ 的大误差，就事后删点；也不能把求解窗口导致的未解析当成可随意剔除的坏数据。

6. 全部实验结果

6.1 12 组状态矩阵

模型 + Harness	任务	模式	完整候选 / 已评分候选	状态
GPT + Codex	普通	Solo	3 / 3	终点评分完成
GPT + Codex	普通	Team	0 / 3	终点评分完成
GPT + Codex	专家	Solo	2 / 3	终点评分完成
GPT + Codex	专家	Team	0 / 3	终点评分完成
Kimi + Kimi Code	普通	Solo	0 / 3	终点评分完成
Kimi + Kimi Code	普通	Team	0 / 3	终点评分完成
Kimi + Kimi Code	专家	Solo	0 / 3	终点评分完成
Kimi + Kimi Code	专家	Team	2 / 3	终点评分完成
DeepSeek + Codex	普通	Solo	0 / 0	本轮无终点结果；主进程等待 Ceph
DeepSeek + Codex	普通	Team	1 / 3	终点评分完成
DeepSeek + Codex	专家	Solo	2 / 3	终点评分完成
DeepSeek + Codex	专家	Team	0 / 0	本轮无终点结果；主进程等待 Ceph

DeepSeek 普通 Solo、专家 Team 的主进程在本轮检查时处于 Ceph 元数据等待，远端没有本项目运行中的 Slurm 作业。这里只报告“未核实终点 + 基础设施阻塞”，不推断其主动停止原因，也不对其候选补造结果。

6.2 30 个候选的统一成绩


“未成功”三列依次为：输入不兼容 / 观测量未解析 / 数值失败。所有候选都有 610 条状态记录；“—”不是遗漏记录，而是不具备完整全池均值。

实验组	物种/反应	物种/反应压缩率	成功/610	全池 E	未成功：输入/未解析/数值
GPT 普通 Solo	101/542	9.0% / 30.9%	610	2.6744	0/0/0
GPT 普通 Solo	87/513	21.6% / 34.6%	610	2.6232	0/0/0
GPT 普通 Solo	81/464	27.0% / 40.8%	610	2.7000	0/0/0
GPT 普通 Team	54/392	51.4% / 50.0%	553	—	57/0/0
GPT 普通 Team	56/402	49.5% / 48.7%	553	—	57/0/0
GPT 普通 Team	69/461	37.8% / 41.2%	553	—	57/0/0
GPT 专家 Solo	93/553	16.2% / 29.5%	610	2.7035	0/0/0
GPT 专家 Solo	88/475	20.7% / 39.4%	610	2.7174	0/0/0
GPT 专家 Solo	74/433	33.3% / 44.8%	595	—	15/0/0
GPT 专家 Team	58/420	47.7% / 46.4%	553	—	57/0/0
GPT 专家 Team	53/374	52.3% / 52.3%	508	—	102/0/0
GPT 专家 Team	49/330	55.9% / 57.9%	449	—	148/13/0
Kimi 普通 Solo	97/712	12.6% / 9.2%	606	—	4/0/0
Kimi 普通 Solo	88/646	20.7% / 17.6%	606	—	4/0/0
Kimi 普通 Solo	80/566	27.9% / 27.8%	560	—	50/0/0
Kimi 普通 Team	66/438	40.5% / 44.1%	593	—	15/0/2
Kimi 普通 Team	58/361	47.7% / 54.0%	493	—	106/11/0
Kimi 普通 Team	48/307	56.8% / 60.8%	492	—	106/11/1
Kimi 专家 Solo	86/613	22.5% / 21.8%	599	—	11/0/0
Kimi 专家 Solo	62/370	44.1% / 52.8%	450	—	160/0/0
Kimi 专家 Solo	49/290	55.9% / 63.0%	377	—	233/0/0
Kimi 专家 Team	80/614	27.9% / 21.7%	610	2.8430	0/0/0
Kimi 专家 Team	70/563	36.9% / 28.2%	609	—	0/0/1
Kimi 专家 Team	70/507	36.9% / 35.3%	610	2.8948	0/0/0
DeepSeek 普通 Team	93/714	16.2% / 8.9%	610	2.6560	0/0/0
DeepSeek 普通 Team	69/522	37.8% / 33.4%	591	—	0/17/2
DeepSeek 普通 Team	63/461	43.2% / 41.2%	547	—	45/17/1
DeepSeek 专家 Solo	103/751	7.2% / 4.2%	610	2.6682	0/0/0
DeepSeek 专家 Solo	89/671	19.8% / 14.4%	610	2.6146	0/0/0
DeepSeek 专家 Solo	68/473	38.7% / 39.7%	550	—	46/13/1

GPT 普通 Solo / Team 最初的端点因机理文件接入格式被判 invalid_mechanism，随后完成了 bulk_v1 修复评测。上表使用修复后的真实求解结果，原始失败文件仍保留；不能把最初的格式接入错误当成这六个机理都没有科学有效性。修复评测复用了代码发布包，运行归属依据原端点合同确定，不依据共享代码目录猜测。

6.3 只比较完整覆盖的候选

实验组	物种/反应	全池 E	相对父机理 E 变化	物种压缩率	反应压缩率
DeepSeek 专家 Solo	89/671	2.6146	-1.99%	19.82%	14.41%
GPT 普通 Solo	87/513	2.6232	-1.67%	21.62%	34.57%
DeepSeek 普通 Team	93/714	2.6560	-0.44%	16.22%	8.93%
DeepSeek 专家 Solo	103/751	2.6682	+0.02%	7.21%	4.21%
GPT 普通 Solo	101/542	2.6744	+0.25%	9.01%	30.87%
GPT 普通 Solo	81/464	2.7000	+1.21%	27.03%	40.82%
GPT 专家 Solo	93/553	2.7035	+1.34%	16.22%	29.46%
GPT 专家 Solo	88/475	2.7174	+1.86%	20.72%	39.41%
Kimi 专家 Team	80/614	2.8430	+6.57%	27.93%	21.68%
Kimi 专家 Team	70/507	2.8948	+8.51%	36.94%	35.33%



完整覆盖候选前沿


图中只画完整覆盖候选。不同颜色代表模型 + Harness 组合，圆点为 Solo、三角为 Team；标注为物种数 / 反应数。虚线是父机理 E。此图是已提交候选的观察性对比，不是已找到真实全局 Pareto 前沿。

三个不同偏好的例子：

- 若优先最低平均 E：当前是 DeepSeek 专家 Solo 89 / 671。
- 若希望明显降低反应数且 E 不高于父机理：GPT 普通 Solo 87 / 513 很有竞争力。
- 若优先减少物种并愿意承担一定 E 退化：Kimi 专家 Team 70 / 507 给出更小的物种集合。

因为第三个候选反应数 507 与 GPT 的 513 接近，但误差更高，不能只依据“70 比 87 小”就说它在所有复杂度指标上大幅领先。

6.4 失败不是边角问题




全部候选覆盖及失败构成

几个典型例子：

- GPT 普通 Team 的三个候选均为 553 / 610：删除 iC4H8、iC4H10、C4H82，失去 46 + 4 + 7 个工况。
- Kimi 普通 Solo 的 97 / 712、88 / 646 都是 606 / 610：全量结果已完成，不再是“仍在计算”；少量输入缺失仍阻止给出全池 E。其最终第三个提交实际为 80 / 566，以终点文件为准，不采用早期计划中的候选计数。
- Kimi 专家 Solo 的三个候选分别覆盖 599、450、377 个工况，逐步压缩也逐步缩小统一评测域覆盖。
- Kimi 专家 Team 的 70 / 563 是 609 / 610，只有一个数值失败。它与大量删燃料导致的失败应分别讨论；不能因差一个点就忽略状态，也不能据此断言其普遍不可用。

- DeepSeek 普通 Team 的 69 / 522 没有输入不兼容，但有 17 个未解析和 2 个数值失败。仅保护全部输入物种，还不够保证动态预测完整。

6.5 分组误差：均值好在哪里，又坏在哪里



图中每格是候选与父机理在同一个燃料×观测组上的 E 差值。蓝色改善，红色退化。色阶为了可读性截断在 ± 2 ；格内数字没有截断。

DeepSeek 89 / 671 的总均值改善，并非所有组都改善。主要有利贡献包括丙烯 LFS、乙炔 LFS、异丁烯 LFS；丁二烯 IDT、2-丁烯 LFS、乙醛 LFS 仍有退化。

GPT 87 / 513 的改善主要来自丙烯 LFS、乙烷 IDT、乙烯 IDT；1-丁烯 IDT 和甲醇 IDT 是值得单独检查的损伤项。

Kimi 70 / 507 相对父机理的全池 E 增加约 0.2271。其中 pC3H4 与 aC3H4 的 IDT 两组分别贡献约 +0.0805、+0.0731，合计约占净增加的 67.6%。这提供了具体诊断目标：不是笼统地说“所有火焰都变差”，而是先检查 C3H4 异构体相关的点火表现。该分解是误差统计贡献，不是已证明损伤由某条反应引起。

6.6 历史 491 / 119 划分上的表现

实验组	物种/反应	原开发 491：E	历史回查 119：E
GPT 普通 Solo	101/542	2.6151	2.9192
GPT 普通 Solo	87/513	2.5586	2.8898
GPT 普通 Solo	81/464	2.6344	2.9706
GPT 专家 Solo	93/553	2.6544	2.9062
GPT 专家 Solo	88/475	2.6655	2.9317
Kimi 专家 Team	80/614	2.8221	2.9296
Kimi 专家 Team	70/507	2.8572	3.0500
DeepSeek 普通 Team	93/714	2.5761	2.9858
DeepSeek 专家 Solo	103/751	2.6118	2.9009
DeepSeek 专家 Solo	89/671	2.5472	2.8927

父机理在原开发 491 点的 E 为 2.6115，在历史回查 119 点为 2.8995。当前自主 Agent 并不是把这 491 点作为统一显式训练输入；这里保留划分只是为了诊断历史分布，不把它解释成标准 train/test 学习曲线。

例如 DeepSeek 普通 Team 93 / 714 在全 610 点上略优于父机理，但在历史 119 点上为 2.9858，反而高于父机理 2.8995。这个反例说明，全池净收益仍可能掩盖某个分布上的退化。

7. 决策轨迹复盘：方法到底做了什么

本节区分证据等级：**终点成绩为本轮读取远端原始文件重新核对；下列过程叙述主要来自先前已记录的轨迹审计，本轮没有因文件系统阻塞而重新逐条读取所有 transcript。** 它们是复盘线索，不能冒充完整的逐步因果证明。

可供专家分析的是公开输出的理由、检索与工具 I/O、代码和行动顺序，不是模型未公开的内部思维链。没有留下记录的搜索关键词或“为什么”不应事后补写成模型原话。

7.1 普通版 GPT：Solo 与 Team 都走了 DRGEP 类路线

环节	Solo 的已记录行为	Team 的已记录行为	专家解释
方法选择	自行选择并实现 DRGEP 类筛选	同样采用 DRGEP 类筛选，再做候选验证 / 调整	Team 更小不意味着用了完全不同、更先进的方法

环节	Solo 的已记录行为	Team 的已记录行为	专家解释
初始覆盖	记录了更宽的燃料范围，约 60 个建图训练工况	建图工况约 99 个，但燃料范围更窄	点数更多不代表领域覆盖更广
进一步删减	直接删减敏感性 / 恢复，记录约 45 个 IDT 筛查点与 63 次单物种删除试验	记录约 24 个 IDT 哨兵点	关键区别可能在验证覆盖和决策规则，而不只是图排名
外部统一评测	3 个候选均成功 610 / 610	3 个候选均为 553 / 610	大幅压缩的一部分来自舍弃统一评测需要的燃料

两个系统都选 DRGEP，说明它是模型容易识别和实现的常见路线，但轨迹没有证明它们系统比较过所有替代方法再得出最优选择。检索 DOI / Crossref 元数据，也不能自动等同于读完原文方法与适用条件。

7.2 专家版 GPT Solo：方法检查更细，但终点没有整体更强

已有轨迹记录包括：更显式地组织多燃料验证、将开发与确认测试分开、做工具一致性检查、通过直接删减和联合验证发现损伤，并恢复相关结构。例如恢复 H2C4O 相关结构用于修复乙炔表现。

这些行为在方法学上有价值，但本轮终点 93 / 553、88 / 475 的 E 均略高于普通 Solo 的 87 / 513；74 / 433 又缺失乙醛工况。**更专业的流程不必然在单次运行里产生更好的精度—压缩折中。**原因可能涉及预算使用、覆盖分配、保守程度、随机轨迹与工具差异，不能只凭结果反推某一步一定错误。

7.3 Kimi：Team 的局部验证与覆盖边界都值得看

Kimi 普通 Solo 曾设计较大的自验证网格；这体现它愿意计算，但仍在最终统一评测缺失输入燃料。自验证调用数很大，只能证明做了这些验证，不能证明已经覆盖目标领域。

Kimi 专家 Solo 的轨迹中出现主动缩小到 C0–C3 / C0–C1 等应用范围的选择；它可以产生对该窄域有意义的机理，但与统一 18 标签评测的覆盖要求不等价。

Kimi 专家 Team 有修改跨工况聚合 / 排名和自写工具的记录，最终得到 80 / 614 和 70 / 507 两个完整覆盖候选。这是正面能力证据。另一方面，改成 mean 或 maximin 一类聚合，并不自动等于标准 DRGEP 或理论更优；要看数学定义、实现对照和跨工况实算。

7.4 DeepSeek：新的终点结果修正了“只会折腾”的简单判断

现在已确认专家 Solo 的 89 / 671、普通 Team 的 93 / 714 都在固定 610 点上得到完整结果，且均值低于父机理。不能继续沿用早期运行尚未结束时“DeepSeek 没有做出有效优化”的判断。

同时，专家 Solo 的 68 / 473 和普通 Team 更激进的两个候选失去完整覆盖。合理解释是：这两条轨迹找到了一定有效压缩区间，但进一步压缩的外部可靠性不足。

本轮尚未完整重读这两条新完成轨迹的公开 rationale 和代码修订顺序，因此不猜测 89 / 671 的具体决策为什么成功，也不把它归为已经验证的 RSI 收益。

8. 深层失败模式：不是简单的“模型笨”

失败模式	可观察表现	深层结构原因 / 解释假设	应怎样验证或改进
用缩小领域代替跨工况压缩	小候选删掉整类输入燃料	优化目标中的“更小”明确，但适用域约束没有贯穿决策	显式记录声明域、证据域、评测域三者的差异
把算例数量当成覆盖	自建上千点仍漏掉某个燃料家族	在熟悉区域密集采样，缺少覆盖矩阵与未验证区域提示	记录燃料×观测×温压范围，而不只计调用数
检索到资源但没有用于决策	找到数据库 / DOI 后只摘少量点	以“找到材料”替代“材料支撑什么选择”	保存查询、重要返回知识、行动影响和原始定位
自验证与自设计共享盲区	验证全部来自同一窄域或同一错误工具	设计者和检查者继承同一假设	独立定义确认覆盖；检查方法实现的基准样例
更改排名却没有验证数学含义	换聚合方式后排名更有区分度	把数值变化当成方法正确或更有科学意义	小图解析例 + 成熟接口对照 + 实际保留集合比较
以 workflow 结束作为停止证据	完成脚本、报告和候选导出就提交	缺少显式的未解决科学风险表	提交前核对仍缺哪些域、误差风险和反例
子 Agent 放大共同假设	文献、代码和测试子任务都只覆盖主 Agent 指定的小域	并行化不等于独立审查，主 Agent 的范围决定影响全队	增加互补覆盖 / 质疑职责，并做消融，不先假定有效
把基础设施等待算成模型慢	有心跳但工具请求排队，或 Ceph 等待	运行状态与科学进度指标混用	分开记录模型等待、工具排队、计算、I/O 与故障

表中“深层原因”是由行为与架构提出的机制解释，不是已经通过干预实验验证的因果关系。最终论文应把可直接观察的事实与解释假设分开。

9. 已发现的工具与工程问题，以及它们能解释多少结果

9.1 DRGEP 图路径的零权边问题

此前独立审计发现，某个自写实现把关联值 r 转为 $-\log(r)$ ，当 $r = 1$ 时得到零权边；使用特定稠密最短路接口时，零被当成无边，导致关联传播错误。三节点例 $A \rightarrow B = 1$ 、 $B \rightarrow C = 0.8$ ，正确关联应为 1、1、0.8，旧实现可能给出 1、0、0。显式稀疏边表示可以避免这类歧义。

但“发现 bug”不等于“它解释了最后所有成绩”。先前记录的实际轨迹回放中，部分排名改变，相关直接阈值保留集合却没有同步改变；某些进一步删除也已被实算拒绝。因此，不能把 Solo / Team 的最终机理大小差异全部归因于这一 bug。

9.2 工具请求被通知与账本操作阻塞

历史实现曾对大量普通流式通知也重复执行预算 / 契约检查和父子账本事务，读取还申请写锁。结果可能是模型已经提出动作，但工具很久才开始执行；心跳仍更新，看起来“活着”。

这属于调度 / 数据访问设计缺陷，不是模型持续思考了几十分钟。后续修复方向是通知快速消费、按时间节流心跳，在真正付费操作、科学提交和状态变化处严格记账。精确到每一分钟的数据库、通知队列和文件系统占比没有完成测量，不能凭估计写入速度结论。

9.3 本轮遇到的 Ceph 阻塞是另一件事

报告编写时，项目目录读操作超时，两条未确认完成的 DeepSeek 主进程等待 Ceph 元数据。远端已有的终点文件仍能通过 SSH 读取，所以本报告取回远端证据并在本地非 Ceph 目录生成。

本轮没有取消、重启或修改这些研究轨迹。没有重新将报告写回受阻塞的 PROJECT_STATUS.md / DECISION_LOG.md；待同步的状态说明单独保存。此故障不应归入 Agent 的科学决策失败，也不能被报告的成功生成掩盖。

9.4 复现记录应该保留什么

对每次行动，理想的可复盘记录应是：当时可见状态 → 公开理由 / 假设 → 查询关键词或工具参数 → 实际返回 → 提取出的关键知识 → 下一动作 → 验证与未决问题。只保存最终总结或源码不足以复盘。

当前已有 transcript / 终点结果等证据路径，但不能声称捕获了模型服务的隐藏提示或私有思维链。本报告不补造缺失 I/O，不把人工事后解释包装成 Agent 当时的思考。

10. 成本与效率：目前能核实到什么程度

下表来自本轮只读查询 Slurm 的分配记录，核时 = 分配核数 × 作业墙钟时间。它是**独立终点评测的节点占用**，不是 Agent 搜索成本，也不是实际进程 CPU。全部对应 64 核分配。

实验组	Job	节点墙钟分钟	分配核时（独立评测）
GPT 普通 Solo	7950591	17.55	18.72
GPT 普通 Team	7950590	7.80	8.32
GPT 专家 Solo	7952916	26.07	27.80
GPT 专家 Team	7952114	18.65	19.89
Kimi 普通 Solo	7955465	27.90	29.76
Kimi 普通 Team	7954669	19.75	21.07
Kimi 专家 Solo	7954173	20.55	21.92
Kimi 专家 Team	7953925	25.27	26.95
DeepSeek 普通 Team	7958655	25.32	27.00
DeepSeek 专家 Solo	7958608	29.73	31.72

GPT 普通版的表中作业是修复后的候选评测；初始失败评测与父机理计算也实际消耗过资源，不能把上表当完整成本总账。其他重试、本地后处理、模型费用、搜索作业、排队和会话停顿也没有全部纳入此表。

因此，当前可以比较候选科学表现，**不能严谨地给出“GPT 比 DeepSeek 快多少倍”“Team 更省多少钱”**。要回答效率问题，需要从权威账本重建：搜索计算 / 独立评测 / 模型 token 或订阅估算 / 基础设施故障 / 排队 / 真正决策时间。

11. 和更早的人类基线、评分提案有什么关系

11.1 Wang 56 / 428 的历史对照

项目更早曾将原生 Astra 的 51 / 49 / 46 物种候选，与文献 Wang 56 物种 / 428 反应机理对齐。这不是当前 12 组提示词 / Team 实验，不能直接并入本报告的统一候选榜单。

此前记录过一个重要现象：在旧的共同成功开发子集上，51 物种候选明显优于 Wang；到共同成功历史回查子集，排序反转。历史摘要记录为：开发 486 点，Wang E $\approx$ 6.3305、51 物种 E $\approx$ 2.8132；回查 118 点，Wang $\approx$ 3.2901、51 物种 $\approx$ 3.8811。**这段是历史记录摘要，本轮因存储阻塞未重取旧原始文件，不作为新增核实结果，也不与当前 610 点 E 直接比较。**

当时“按回查的燃料 $\times$ 观测比例重加权，开发优势几乎消失”的含义是：保持每个组内部的开发误差不变，只把各组的权重改成回查分布，查看总分是否改变。它提示领域组成可能解释一部分排名变化；不等于改了原始实验值，也不独自证明过拟合或某种模型因果缺陷。重加权不能创造开发中没有的组或未测反应区域。

若要把“超过人类简化机理”作为当前论文主结论，必须重新锁定同一任务域、观测算子、候选版本与完整评分，并核清该文献机理原本为哪些燃料和应用设计。不能用广域任务处罚窄域文献机理后直接宣称人类方法落后。

11.2 Rubric 与定量 grader

已有辅助科研评审设计包括 Taste、Methodology、Novelty、Solid、Robust，以及 Agent 决策质量，建议按 0-4 / NA 给出基于证据的评价。它应读真实端点结果与过程证据，而非只读 Agent 自己的报告。

但本轮未核实完整的既有 rubric 评分产物，也没有新增付费 LLM-as-judge 调用，因此这里不编造六维分数；“本轮没有核实”不等于断言之前从未执行评审。Rubric 是探索性辅助，不替代统一误差、压缩率和覆盖率的客观结果。

12. 目前哪些结论可写，哪些不能写

命题	当前证据判断	边界
Agent 能自主产生有用的 USC-II 简化候选	有终点实算支持	限于本任务与已观察轨迹，不代表普遍成功
已得到完整 610 覆盖、误差略优于父机理的压缩机理	有支持：GPT 87/513、DeepSeek 89/671 与 93/714	是当前均值结果，缺少重复和显著性分析
大幅物种压缩常伴随覆盖或误差损失	本批候选存在明确实例	不是对所有方法的理论下界
Team 一定优于 Solo	不支持	GPT 与 Kimi 的方向不同，且 GPT 是混合模型团队
专家提示一定提高结果	不支持	Kimi Team 有正例，GPT 没有统一增益
更大量的自验证等于更充分的跨工况覆盖	不支持	多个候选遗漏了固定池输入域
已证明 RSI / memory / skill 进化有效	尚不支持	缺少明确版本干预、后续验证与配对对照

命题	当前证据判断	边界
已超过人类最优简化方法	尚不支持	旧 Wang 对照有任务域和分布边界，未纳入当前统一比较
在 PDE 上有证据	有一维 LFS 证据	不等于二维 / 三维反应流、旋流或 soot 证据
可以评出模型 / Harness 的普遍优劣	不支持	模型与 Harness 混淆、单次轨迹、成本与故障未完整控制

上述“有支持”均指内部工作稿可描述的观察，不代表已经通过项目审查晋升为论文主张。主要论文结论仍需专家 review。

13. 当前最值得写成论文的问题

本轮可以围绕一个收敛的实证问题组织论文：

自主科学 Agent 能否在自行设计验证数据的情况下，实现跨工况可靠的化学机理压缩？其局部成功为什么不能自动转化为广域可靠性？

潜在结构如下：

5. 问题与价值：宏观反应动力学的多目标压缩，难点不是只写一个优化器，而是定义和维护证据覆盖。
6. 环境与任务：父机理、公开信息获取、Agent 自建验证、统一独立评测；区分搜索与终点核时。
7. 对照：三种模型 / Harness 组合，普通 / 专家提示，Solo / Team；清楚承认探索性设计的混淆因素。
8. 结果：完整报告候选复杂度、误差、覆盖和失败；以分组热图解释均值，而不是只展示一个最优节点。
9. 过程分析：任务域替换、数量替代覆盖、检索不落地、自验证共同盲区、停止判断。
10. 局限与下一步：文献观测算子复核、重复轨迹、成熟底座上的覆盖 / 记忆策略干预，以及真正的 RSI 后续阶段检验。

这份材料更接近“能力与评价边界”的实证工作稿。把它提升为 RSI 算法论文，还需要独立的算法干预与因果证据，不能仅改标题。

14. 下一步主线、审查点与数据使用说明

14.1 本轮不扩展出题、不启动新实验

用户已暂停出题。本次产物只整理理论、实验和证据，不生成新的合成训练集，不改变评分，不重新开放历史回查反馈，也不向外部人员或飞书空间自动发布。

14.2 按优先级收尾

11. 文件系统恢复后，同步本报告并核清剩余两条 DeepSeek 的终止状态、完整成本与关键 transcript；保留故障和恢复版本，不能抹掉失败记录。
12. 补齐当前模型身份 / 任务快照与最终候选之间的索引；把已知的过程审计转成可逐条定位的中文专家复盘。
13. 完成 benchmark 中观测定义、实验批次和不确定度语义审计。若要改变冻结评分规则，先记录理由并提交专家审查，不能依据成绩删点。

14. 若继续做算法创新，优先检验“覆盖驱动的验证与停止”或“可验证的程序记忆”中的一个变量；保持模型、任务和评测一致，做配对重复。此处是建议，不是本轮新授权运行。

14.3 大图景位置

长期路线为：living mechanism 问题定义 → benchmark → Agent / RSI 算法证据 → 规模化 PDE → 少量 3D 迁移 → SootGEN / 专家合作验证 → 投稿。

当前处于 **benchmark 与成熟 Harness 强基线的实证整理阶段**，已经有一维 PDE 终点评测，尚未进入可宣称 RSI 成功或多维反应流泛化的阶段。当前材料的价值，是把“系统能跑”“候选更小”“科学可靠”“策略进化”拆开，避免以后用工程成功代替科学结论。

14.4 证据与文件说明

- 报告正文、表格和图均可导入 / 复制到飞书；未声称已经创建在线飞书文档。
- candidate_results.csv：30 个候选的复杂度、覆盖、误差、分位数和来源。
- case_results.csv：18,300 条候选×工况结果。失败保留状态，不补造误差。
- fuel_observable_results.csv：燃料×观测分组误差与覆盖。
- results.json：机器可读汇总、验证记录、运行归属和原始证据路径。
- evidence/：从远端终点评测读取的 JSON 证据快照，包括保留的旧接入失败版本；不是完整 Agent transcript。
- figures/：可直接放入文档的四幅静态图。
- PENDING_PROJECT_UPDATES.md：Ceph 恢复后应同步的状态与决策记录，本轮未假装已经写回项目。

为避免阅读正文被路径打断，完整来源映射与运行 ID 在附录及 JSON 中提供。证据快照是读取后格式化保存的 JSON，保留语义与字段；不是声称远端文件逐字节原样复制。附带校验值用于记录本次产物，不代表证明历史从未被修改。

附录 A：固定池燃料分布

燃料标签	工况数
c2h6	97
c2h4	71
c3h8	67
c3h6	53
ch4	48
ic4h8	46
c4h6	45
pc3h4	26
c4h81	24
c2h2	21
h2	21
ch3oh	20

燃料标签	工况数
ac3h4	20
ch3cho	15
c4h10	13
h2plusco	12
c4h82	7
ic4h10	4

附录 B：运行与端点评测来源映射

实验组	运行目录	远端评测目录 / Job
GPT 普通 Solo	solo-20260915T131056.265011Z-108d5c07	cfx_astra_3a9fcc9a572e45bfb6a6fcb6_endpoint_bulk_v1 / 7950591
GPT 普通 Team	team-20260915T131059.107037Z-e89a0b43	cfx_astra_ca02e2d6c3b1457f9b99bb1a_endpoint_bulk_v1 / 7950590
GPT 专家 Solo	expert-v2-solo-20260915T173616.942323Z-0bbd299d	cfx_astra_eaab23cebb934bb2ba9f69f0_endpoint / 7952916
GPT 专家 Team	expert-v2-team-20260915T173617.847670Z-2c1bfc9d	cfx_astra_61bc9612470e4d46ab08ef0e_endpoint / 7952114
Kimi 普通 Solo	baseline-v1-kimi-solo-20260916T010433.416187Z-99dd4120	cfx_astra_8975b1c396724bdfaca362a1_endpoint / 7955465
Kimi 普通 Team	baseline-v1-kimi-team-20260916T010434.254556Z-33182164	cfx_astra_12fe63bc0f88475da6b6dc79_endpoint / 7954669
Kimi 专家 Solo	expert-v2-kimi-solo-20260916T002108.637960Z-d26b7970	cfx_astra_240e744073cd4af98f8d729f_endpoint / 7954173
Kimi 专家 Team	expert-v2-kimi-team-20260916T002109.891728Z-d9881267	cfx_astra_8b7403c260e04d29bdda493a_endpoint / 7953925
DeepSeek 普通 Team	baseline-v1-deepseek-team-20260916T052223.858290Z-614995a1	cfx_astra_e598e3112e8446a08ba0586d_endpoint / 7958655
DeepSeek 专家 Solo	expert-v2-deepseek-solo-20260916T052223.859010Z-0831cedf	cfx_astra_f61e625cdc7842b397ddfa9c_endpoint / 7958608

完整远端根目录为 /public3/home/sca2070/WORK/Caifeixue/AgenticRL_research_runs。目录中的 cfx_astra_ 是历史通用命名前缀，不能据此判断模型是 Astra；应依据对应轨迹与合同归属。

附录 C：术语速查

术语	本报告中的含义
case / 工况	一个明确的输入、观测定义与实验目标
candidate / 候选	一个锁定的机理文件版本
candidate × case	一个机理在一个工况上的评测记录
solver invocation	一次实际求解，重试与时间窗口扩展可能增加调用
coverage	这里是成功求解比例，不是误差低于阈值的通过率
E / signed_sigma	按实验不确定度标准化的宏观误差，不是百分比
Harness	管理模型、工具、上下文、会话与执行的底座
skill / 程序记忆	可复用方法与其适用条件；存在文件不代表进化已有效
RSI	后续可复用的研究策略 / 能力改进，而不只是当前候选变小

文档结束。本文所有新增数字分析均来自已完成评测文件的后处理；没有新增求解、模型评审或未声明的实验干预。